TALLER N° 3

JESSICA ANDREA PARRA RIAÑO
JUAN PABLO VALERO BUITRAGO

UNIVERSIDAD ECCI
FACULTAD DE INGENIERÍA
PROGRAMA DE INGENIERÍA INDUSTRIAL
BOGOTÁ, D.C.

AÑO 2026

TALLER N° 3

JESSICA ANDREA PARRA RIAÑO
JUAN PABLO VALERO BUITRAGO

Taller N° 3

FREDY ALEXANDER ORJUELA LOPEZ
Docente de Sistemas Avanzados de Producción y Python

UNIVERSIDAD ECCI
FACULTAD DE INGENIERÍA
PROGRAMA DE INGENIERÍA INDUSTRIAL
BOGOTÁ, D.C.
AÑO 2026

TABLA DE CONTENIDO

1. Captura de pantalla de la interfaz de LMArena mostrando el modo Direct Chat con un modelo seleccionado....4
2. Captura de la respuesta del modelo a tu prompt de prueba....5
3. Batalla resumen....6
4. Batalla de expansión (escritura profesional)....9
5. Batalla de transformación....10
6. Batalla de inferencia (interpretación textual)....11
7. Batalla de razonamiento....14

1. **Captura de pantalla de la interfaz de LMArena mostrando el modo Direct Chat con un modelo seleccionado.**

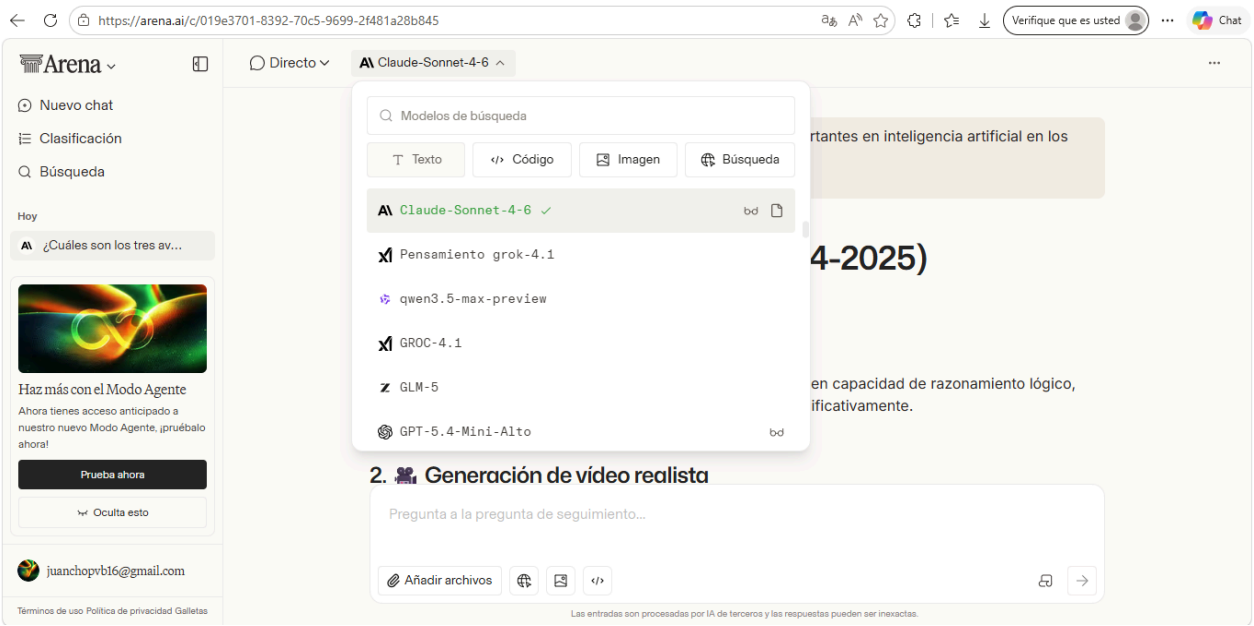

2. Captura de la respuesta del modelo a tu prompt de prueba.

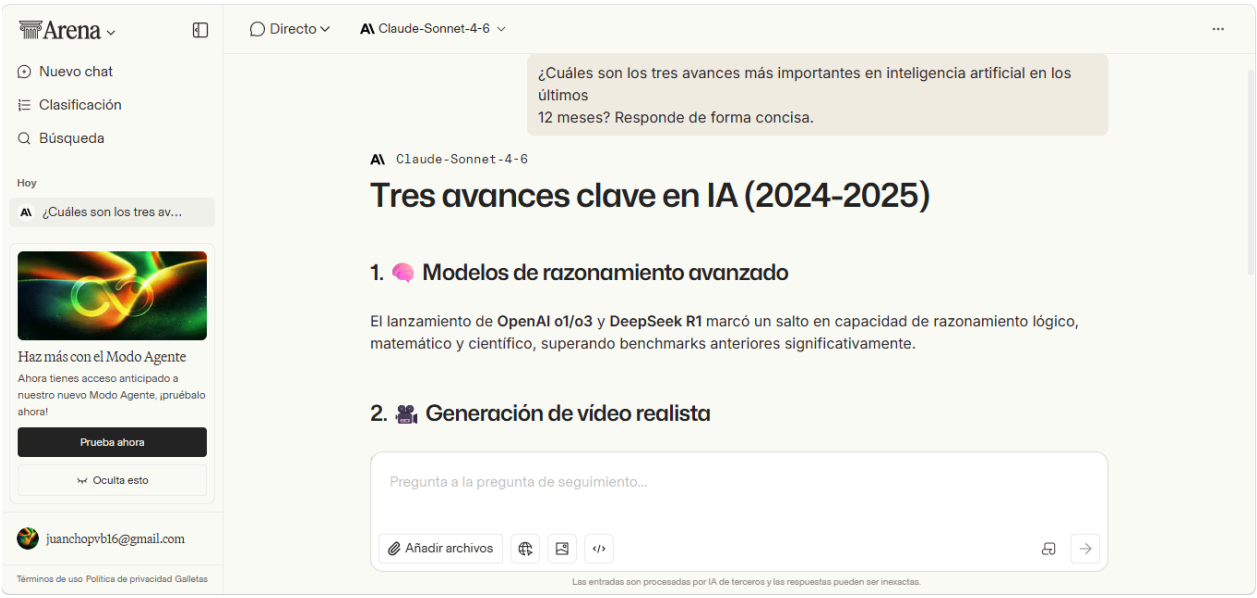

3. Batalla resumen

`gemini-3-flash-grounding` `claude-opus-4-7-search`

Arena
New Chat
Leaderboard
Search
Today
Realiza un resumen d...
Realiza un resumen d...
Do more with Agent Mode
You now have early access to our new Agent Mode, try it out now!
Try now
Hide this
juanchopvb16@gmail.com
Terms of Use
Privacy Policy
Cookies
Battle Mode
Realiza un resumen de 3 párrafos de la siguiente noticia:
https://www.theguardian.com/commentisfree/2026/may/08/how-dangerous-is-anthropics-mythos-ai
gemini-3-flash-grounding
Sources
Aquí tienes un resumen de tres párrafos sobre el artículo de Bruce Schneier en *The Guardian*:
En mayo de 2026, Anthropic anunció el desarrollo de **Claude Mythos Preview**, un modelo de inteligencia artificial con una capacidad sin precedentes para identificar y explotar vulnerabilidades de seguridad en software. 1 2 3 Debido a su alta efectividad —capaz de hallar fallos de "día cero" en los principales sistemas operativos y navegadores con un 83% de precisión—, la compañía decidió no lanzarlo al público general, limitando su acce
claude-opus-4-7-search
Sources
Resumen: "¿Qué tan peligrosa es la IA Mythos de Anthropic?" (The Guardian)
Párrafo 1: El anuncio y su contexto
1 El mes pasado, Anthropic hizo un anuncio destacado sobre su nuevo modelo, Claude Mythos Preview: era tan bueno detectando
Ask followup...
Search
Inputs are processed by third-party AI and responses may be inaccurate.

Arena
New Chat
Leaderboard
Search
Today
Realiza un resumen d...
Realiza un resumen d...
Do more with Agent Mode
You now have early access to our new Agent Mode, try it out now!
Try now
Hide this
juanchopvb16@gmail.com
Terms of Use
Privacy Policy
Cookies
Battle Mode
gemini-3-flash-grounding
limitando su acceso a un grupo selecto de empresas para labores de defensa. Esta decisión subraya un momento crítico en la ciberseguridad, donde la IA transforma el descubrimiento de errores informáticos en un proceso industrial automatizado.
A pesar de la alarma generada por Anthropic, el autor Bruce Schneier matiza que Mythos no es el único modelo con este poder; sistemas como GPT-5.5 de OpenAI presentan capacidades similares. 3 Schneier sugiere que la negativa de Anthropic a un lanzamiento abierto podría ser tanto una estrategia de marketing para elevar su valoración como una necesidad técnica ante los altos costes operativos del modelo. 3 No obstante, el riesgo es real: la facilidad para encontrar y explotar vulnerabilidades suele superar la velocidad de los parches de seguridad, lo que otorga una ventaja inicial peligrosa a los atacan ya sean cibercriminales o actores estatales.
claude-opus-4-7-search
vulnerabilidades de seguridad en software que la compañía no lo lanzaría al público general. En su lugar, solo estaría disponible para un grupo selecto de empresas para escanear y arreglar su propio software. Sin embargo, Bruce Schneier matiza esta narrativa: 1 aunque el modelo de Anthropic es realmente bueno encontrando vulnerabilidades, otros modelos también lo son. El Instituto de Seguridad de IA del Reino Unido encontró que GPT-5.5 de OpenAI, ya disponible al público, tiene una capacidad comparable. La empresa Aisle reprodujo los resultados publicados por Anthropic con modelos más pequeños y baratos. Además, el autor sugiere que 7 la negativa de Anthropic a liberar públicamente su nuevo modelo convierte una necesidad en virtud, ya que Mythos es muy caro de ejecutar y la empresa no parece tener los recursos para un lanzamiento general; insinuar capacidades sin demostrarlas resulta una forma efectiva de inflar la valuación la compañía.
Ask followup...
Search
Inputs are processed by third-party AI and responses may be inaccurate.

Arena
New Chat
Leaderboard
Search
Today
Realiza un resumen d...
Realiza un resumen d...
Do more with Agent Mode
You now have early access to our new Agent Mode, try it out now!
Try now
Hide this
juanchopvb16@gmail.com
Terms of Use
Privacy Policy
Cookies
Battle Mode
gemini-3-flash-grounding
riesgo es real: la facilidad para encontrar y explotar vulnerabilidades suele superar la velocidad de los parches de seguridad, lo que otorga una ventaja inicial peligrosa a los atacantes, ya sean cibercriminales o actores estatales.
Finalmente, el artículo advierte que las implicaciones de esta tecnología trascienden lo digital. Las mismas capacidades de razonamiento y búsqueda de patrones de la IA podrían aplicarse a sistemas complejos como el código tributario o las normativas legales para descubrir "lagunas" o vacíos legales. 3 Mientras que el software puede parchearse en días, los sistemas sociales y legislativos tardan años en actualizarse, lo que plantea un futuro volátil donde la IA podría facilitar la evasión de reglas a una escala masiva, alterando profundamente la estabilidad financiera y social a nivel global.
claude-opus-4-7-search
Párrafo 2: Implicaciones para la ciberseguridad Más allá del marketing, Schneier sostiene que la realidad subyacente es preocupante. 7 Los sistemas modernos de IA generativa —no solo los de Anthropic, sino también los de OpenAI y otros modelos de código abierto— son cada vez mejores encontrando y explotando vulnerabilidades en software, lo que tiene importantes ramificaciones para la ciberseguridad, tanto en la ofensiva como en la defensiva. 1 Los atacantes usarán estas capacidades para encontrar y hackear automáticamente vulnerabilidades en sistemas de todo tipo, irrumpiendo en infraestructuras críticas para instalar ransomware, robar datos con fines de espionaje o controlar sistemas en momentos de hostilidad, haciendo el mundo más peligroso y volátil. No obstante, 1 los defensores usarán las mismas capacidades para encontrar y parchear muchos de esos mismos sistemas; por ejemplo, Mozilla usó Mythos para encontrar 271 vulnerab des en Firefox.
Ask followup...
Search
Inputs are processed by third-party AI and responses may be inaccurate.

Justificación: El Asistente A logra un resumen más equilibrado y elegante. Sus tres párrafos fluyen de forma natural, respetan el tono editorial del artículo original de The Guardian y sintetizan las ideas clave sin sobrecargar al lector. Si bien el Asistente B es más exhaustivo en detalles (como el ejemplo de Mozilla o la mención explícita al DSIT), esa exhaustividad lo aleja del propósito de un resumen, convirtiéndolo en una paráfrasis extensa con estructura de reporte. Para el prompt solicitado tres párrafos de resumen la respuesta A cumple mejor el objetivo con mayor precisión formal.

4. Batalla de expansión (escritura profesional)

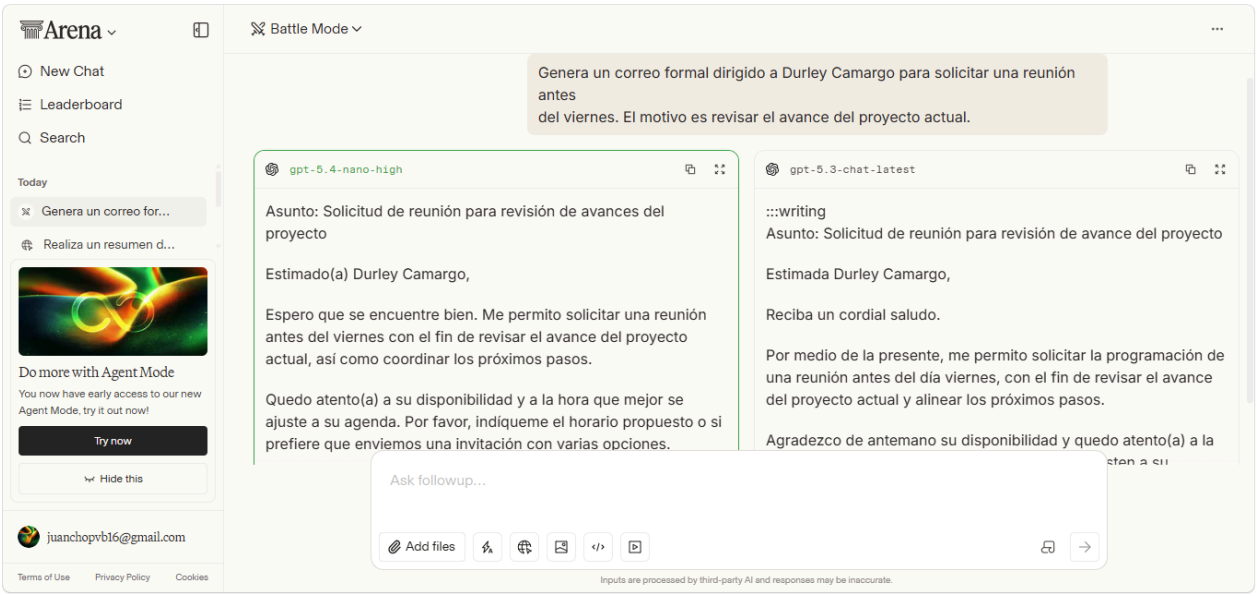

Justificación: Ambos correos son formales, completos y cumplen el objetivo del prompt. El Asistente A destaca por ofrecer una firma más detallada y por proponer activamente opciones de horario, lo que agrega valor práctico. Sin embargo, su segundo párrafo resulta algo denso al mezclar dos peticiones. El Asistente B es más limpio, directo y estilísticamente más pulido, su estructura de un solo párrafo central es más eficiente para un correo formal breve. Ninguno comete errores; la diferencia es de estilo y economía del lenguaje, lo que justifica un empate técnico.

5. Batalla de transformación

Justificación: El Asistente A cumple plenamente con la tarea: transforma el texto en algo que un niño de 5 años realmente entendería y disfrutaría. Usa comparaciones concretas ("como tú comes para tener fuerza"), lenguaje lúdico, emojis y exclamaciones que capturan la atención infantil. El Asistente B apenas simplifica una oración sin realmente cambiar el registro mantiene términos como "fotosíntesis" y "energía" que un niño de esa edad no comprende, lo que representa un fallo directo frente al prompt. La diferencia no es de estilo sino de cumplimiento del objetivo. Dijiste: Batalla de inferencia (interpretación textual).

6. Batalla de inferencia (interpretación textual)

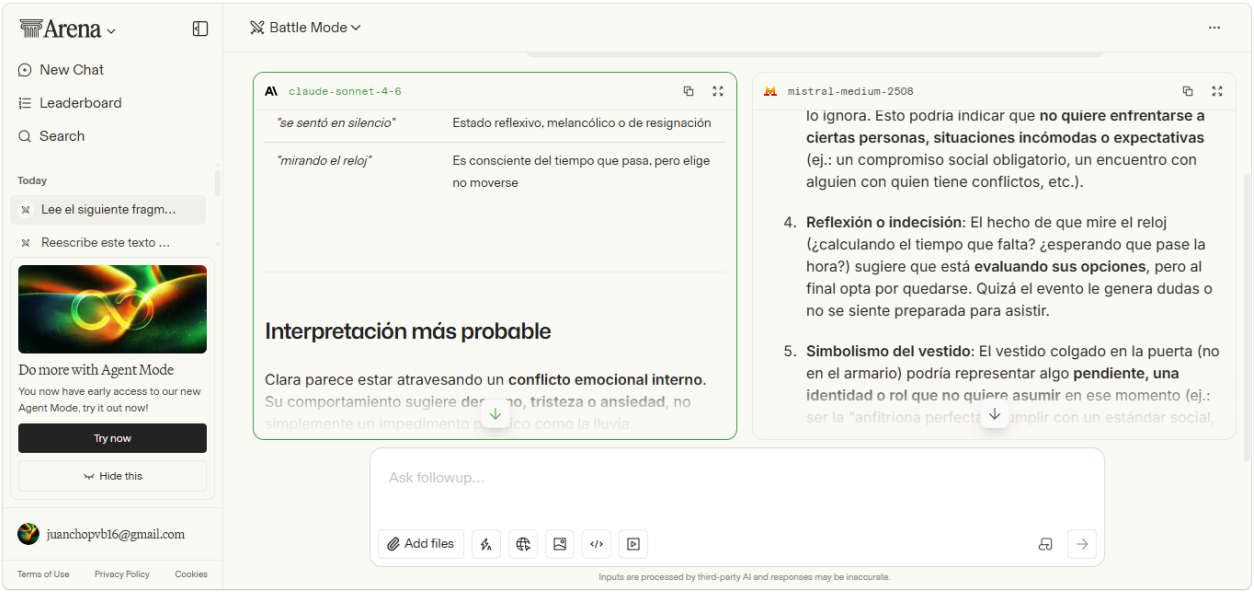
Arena
New Chat
Leaderboard
Search
Today
Lee el siguiente fragm...
Reescribe este texto ...
Do more with Agent Mode
You now have early access to our new Agent Mode, try it out now!
Try now
Hide this
juanchopvb16@gmail.com
Terms of Use
Privacy Policy
Cookies
Battle Mode
claude-sonnet-4-6
"se sentó en silencio"
Estado reflexivo, melancólico o de resignación
"mirando el reloj"
Es consciente del tiempo que pasa, pero elige no moverse
Interpretación más probable
Clara parece estar atravesando un conflicto emocional interno.
Su comportamiento sugiere
tristeza o ansiedad, no
mistral-medium-2508
lo ignora. Esto podría indicar que no quiere enfrentarse a ciertas personas, situaciones incómodas o expectativas (ej.: un compromiso social obligatorio, un encuentro con alguien con quien tiene conflictos, etc.).
4. Reflexión o indecisión: El hecho de que mire el reloj (¿calculando el tiempo que falta? ¿esperando que pase la hora?) sugiere que está evaluando sus opciones, pero al final opta por quedarse. Quizá el evento le genera dudas o no se siente preparada para asistir.
5. Simbolismo del vestido: El vestido colgado en la puerta (no en el armario) podría representar algo pendiente, una identidad o rol que no quiere asumir en ese momento (ej.:
Ask followup...
Add files
Inputs are processed by third-party AI and responses may be inaccurate.

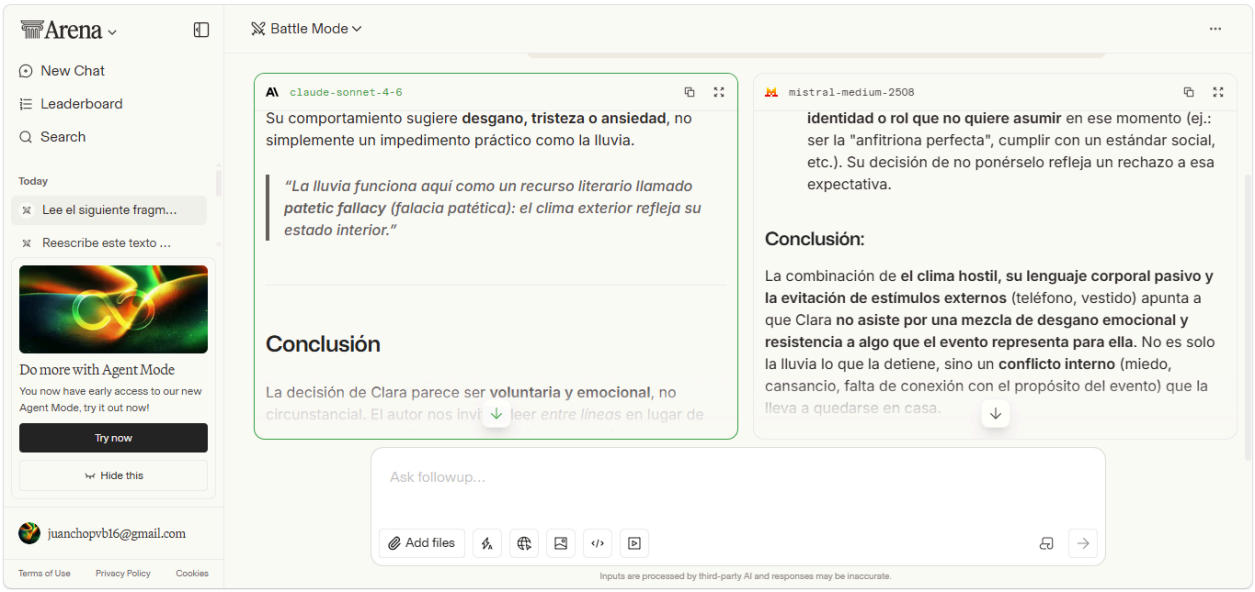

Justificación: Ambas respuestas son sólidas, pero el Asistente A demuestra mayor elegancia analítica. Su estructura (tabla de pistas → interpretación central → conclusión) es más eficiente y pedagógica, y la mención de la pathetic fallacy eleva la respuesta a un nivel de análisis literario genuino. El Asistente B es más exhaustivo pero cae en el exceso: algunas inferencias como el simbolismo de la ubicación del vestido o las "expectativas sociales" se alejan del texto sin suficiente respaldo, comprometiendo la cautela interpretativa. Para una tarea de inferencia textual, la precisión y la justificación bien delimitada pesan más que la cantidad de hipótesis.

7. Batalla de razonamiento

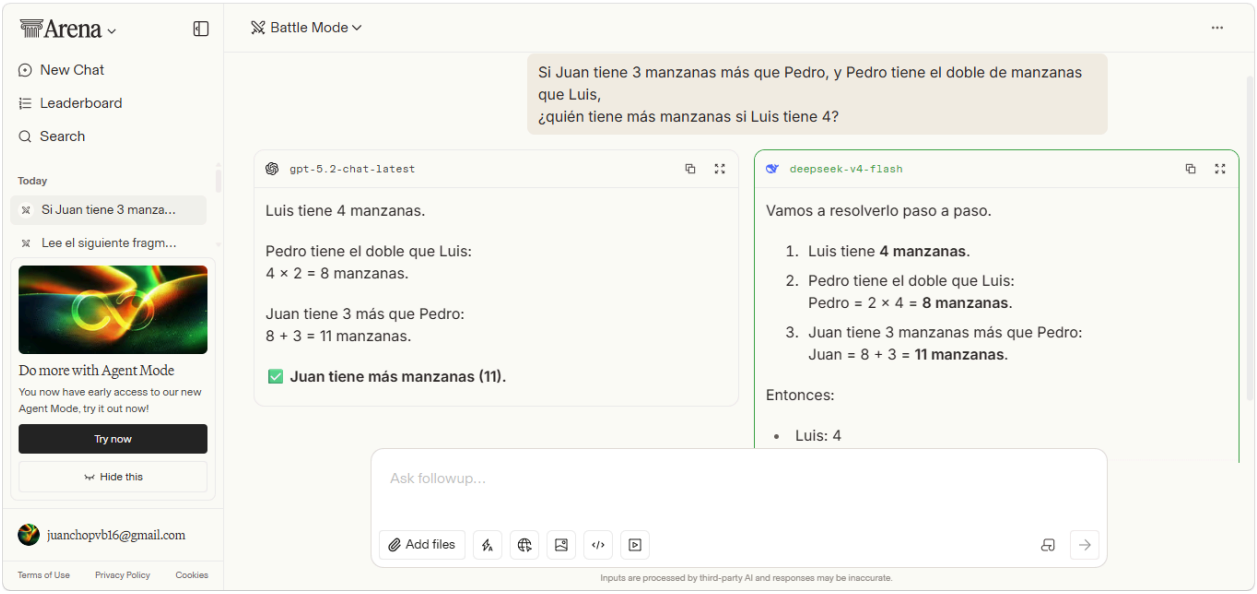

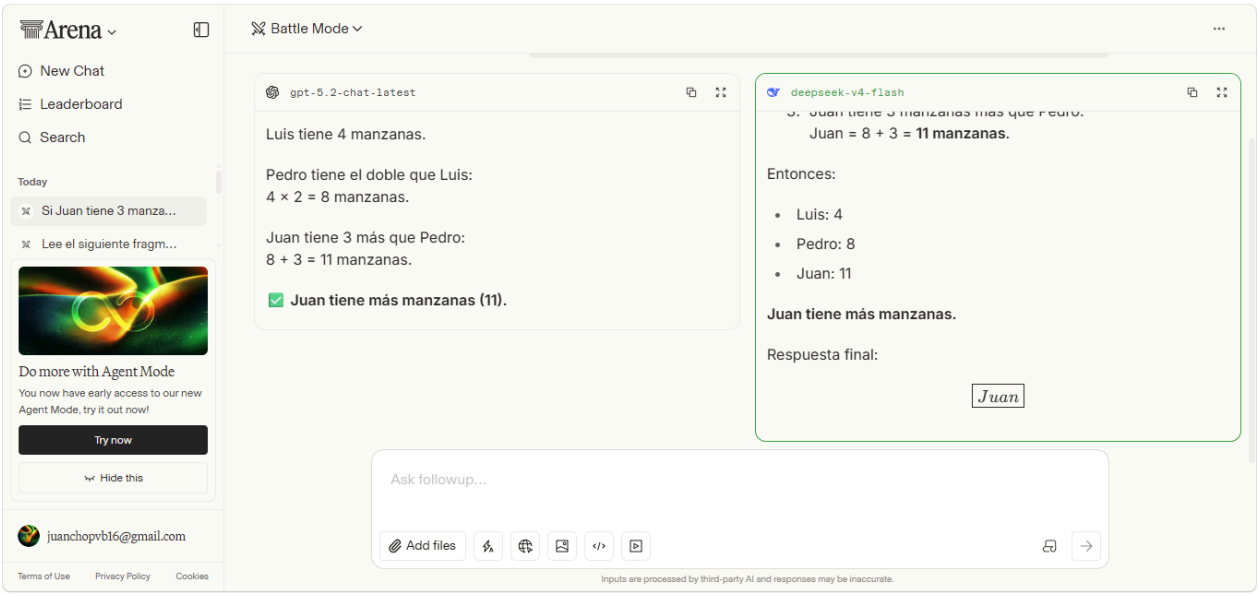

Justificación: Ambos modelos llegan al resultado correcto con un proceso claro y paso a paso. La diferencia es de presentación: el Asistente A es más limpio y directo, ideal para una respuesta rápida. El Asistente B añade valor con el resumen comparativo de los tres valores al final, que actúa como verificación implícita y facilita la comprensión global del problema. Ninguno verifica formalmente sustituyendo los valores de vuelta en las condiciones originales, lo cual sería el estándar ideal. En razonamiento matemático, esa transparencia adicional del B marca una diferencia mínima pero real.

Conclusión

A lo largo de las cinco batallas, el Asistente A se mostró consistentemente más capaz en tareas que exigen criterio editorial, sensibilidad lingüística y análisis literario: dominó con claridad en el resumen de noticia, la adaptación de registro infantil y la inferencia textual, demostrando mejor manejo del tono, la economía del lenguaje y la profundidad interpretativa. El Asistente B, por su parte, fue más exhaustivo y detallado en casi todas las respuestas, pero esa misma exhaustividad jugó en su contra: tendió a sobreexplicar, a incluir inferencias poco respaldadas y a priorizar la cantidad sobre la precisión, lo que diluyó la calidad de sus respuestas. La única área donde ambos empataron fue en tareas más estructuradas el correo formal y el razonamiento matemático, donde el formato cerrado dejaba menos margen para diferenciarse. En cuanto al leaderboard de LMArena, esta impresión coincide parcialmente: los modelos mejor posicionados suelen destacar precisamente en tareas abiertas de comprensión y generación de lenguaje natural, no solo en benchmarks matemáticos o de código, lo que sugiere que el Asistente A podría corresponder a un modelo de mayor rango en el índice de la plataforma, aunque sin conocer la identidad de los modelos evaluados, esa correlación permanece como hipótesis razonable más que como certeza verificable.